



دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

پایان‌نامه‌ی کارشناسی

عنوان:

قطعه‌بندی خودنظارتی سلول‌ها در تصاویر میکروسکوپی

نگارش:

بهار جهانی

استاد راهنما:

دکتر محمد حسین رهبان

مهر ۱۳۹۹



به نام خدا
دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

پایان‌نامه‌ی کارشناسی

عنوان: قطعه‌بندی خودنظارتی سلول‌ها در تصاویر میکروسکوپی
نگارش: بهار جهانی

کمیته‌ی ممتحنین

استاد راهنما: دکتر محمد حسین رهبان امضاء:

استاد مشاور: استاد مشاور امضاء:

استاد مدعو: استاد ممتحن امضاء:

تاریخ:

چکیده

با توجه به پیشرفت گسترده در مراحل عکس برداری از سلول‌های بافت، شناسایی و تشخیص بیماری‌های پیچیده با استفاده از روش‌های یادگیری ماشین بسیار اهمیت یافته است. تشخیص مشخصات سلول از قبیل اندازه و شکل از فاکتورهای مهم در تشخیص نوع سلول‌ها هستند، که با استفاده از روش‌های یادگیری مانند آموزش یک شبکه عصبی عمیق می‌توان به این مهم دست پیدا کرد. در این پروژه قصد داریم که به قطعه‌بندی سلول‌ها در تصاویر میکروسکوپی با روش خود نظارتی بپردازیم. هدف از قطعه‌بندی این تصاویر، تشخیص هسته در انواع سلول است. دادگان تصویری مورد استفاده به منظور تشخیص هسته سلول داده‌های Kaggle Data Science Bowl 2018 است، که اکنون در دسترس عموم است.

کلیدواژه‌ها: یادگیری خود نظارتی، قطعه‌بندی سلول‌ها، تشخیص هسته، شبکه عصبی

فهرست مطالب

۹	۱ مقدمه
۹	۱-۱ اهمیت موضوع
۹	۲-۱ تعریف مسئله و ادبیات موضوع
۱۰	۳-۱ اهداف تحقیق
۱۱	۴-۱ ساختار پایان نامه
۱۲	۲ مفاهیم اولیه
۱۲	۱-۲ یادگیری خودنظارتی
۱۳	۲-۲ شبکه عصبی UNET
۱۴	۳ کارهای پیشین
۱۶	۴ روش پیشنهادی
۱۶	۱-۴ مجموعه داده سه گانه
۱۸	۲-۴ رویکرد خودنظارتی و وظیفه های نماینده
۱۸	۱-۲-۴ یادگیری سه گانه مقیاسی
۱۹	۲-۲-۴ شمارش رتبه بندی

۱۹	۳-۴ تنظیم روی وظیفه‌ی اصلی
۲۱	۵ آزمایش‌ها و نتایج
۲۱	۱-۵ مجموعه داده
۲۱	۱-۱-۵ مجموعه داده MoNuSeg 2018
۲۲	۱-۲-۵ مجموعه داده Kaggle Data science Bowl 2018
۲۲	۲-۵ جمع‌بندی آزمایش
۲۳	۳-۵ ارزیابی و عملکرد
۲۵	۴-۵ پیشنهادات برای بهبود مدل در آینده
۲۶	۶ نتیجه‌گیری

فهرست شکل‌ها

- ۱-۲ مدل UNET استفاده شده ۱۳
- ۱-۴ نمونه‌های لنگر (برش قرمز)، مثبت (برش آبی) و منفی (برش سبز) در مجموعه داده‌ی ۱۷
- MoNuSeg ۱۷
- ۲-۴ مدل رمزگذار با وزن‌های مشترک ۱۸
- ۱-۵ نمودار اتلاف بخش خودنظارتی مدل ۲۴
- ۲-۵ نتایج حاصل از ۳۰ دور آموزش رمزگذار و ۳۰۰ دور آموزش UNET، $mAP=0.44$ ۲۵
- ۳-۵ نتایج حاصل از ۱۰ دور آموزش رمزگذار و ۵۰۰ دور آموزش UNET، $mAP=0.48$ ۲۵

فهرست جدول‌ها

۲۴	۵-۱ نتایج ارزیابی
----	-------------------------

فصل ۱

مقدمه

این فصل به بیان اهمیت موضوع، معرفی مسئله و ادبیات موضوع، اهداف تحقیق و معرفی ساختار پایان‌نامه می‌پردازد.

۱-۱ اهمیت موضوع

قطعه‌بندی هسته‌ی سلول‌ها نه تنها اطلاعاتی درباره موقعیت و چگالی آنها به ما می‌دهد، بلکه ویژگی‌های ریخت‌شناسی^۱ زیادی (مانند اندازه و نسبت سیتوپلاسمی) برای تشخیص تومور و رویه‌های درمانی مرتبط به ما می‌دهد [۲]. به همین دلیل، تحقیقات زیادی برای ایجاد سیستم‌های خودکار برای تقسیم بندی دقیق هسته‌ها ارائه شده است.

۱-۲ تعریف مسئله و ادبیات موضوع

اگرچه رویکردهای مبتنی بر یادگیری عمیق به دقت قطعه‌بندی برجسته‌ای برای نمونه‌های هسته رسیده‌اند، اما کمبود داده‌های حاشیه‌نویسی شده^۲، یک چالش مشترک برای پیشرفت بیشتر این روش‌هاست. با توجه به وجود گسترده و واریانس‌های ریخت‌شناسی بزرگ هسته‌ها، حاشیه‌نویسی نمونه‌های هسته‌ای به

^۱Morphology
^۲annotated

پزشکان مجرب نیاز دارد تا تصاویر هیستوپاتولوژی را به طور مکرر بررسی کرده و خطوط را با دقت ترسیم کنند، که کاری بسیار سخت و هزینه‌بر است. بنابراین، عملکرد رویکردهای مبتنی بر یادگیری عمیق از کمی تعداد تصاویر هیستوپاتولوژیک حاشیه نویسی شده رنج می‌برد. وظیفه مکان یابی اتوماتیک هسته‌ها امروزه با یادگیری عمیق و یادگیری ماشین دست یافتنی شده به همین دلیل Kaggle مسابقاتی را در همین راستا با عنوان Kaggle BOWL 2018 ایجاد کرد که باعث شد راه حل های جدیدی در برای یافتن هسته سلول عنوان شود. همچنین Kaggle دادگان این مسابقه را در دسترس عموم قرار داده تا بهترین راه حل در این مسیر یافت شود. یادگیری خود نظارتی، به عنوان راه‌حلی برای از بین بردن نیاز به حاشیه نویسی دستی برای شبکه‌های عصبی، توجهات روزافزون جامعه را به خود جلب کرده است. خط لوله^۳ معمولاً از دو مرحله تشکیل شده است:

۱. مدل شبکه از قبل روی یک وظیفه‌ی نماینده^۴ را با یک مجموعه داده‌ی بزرگ بدون برچسب آموزش می‌دهیم.

۲. با مجموعه‌ای کوچک از داده‌های حاشیه‌نویسی شده، شبکه از پیش آموزش دیده را برای وظیفه‌ی خاص هدف تنظیم^۵ می‌کنیم.

مطالعات اخیر اثربخشی یادگیری خود نظارتی بر کارهای مختلف پردازش تصویر پزشکی مانند قطعه‌بندی منطقه مغزی، قطعه‌بندی تومور مغزی^[۳] و قطعه‌بندی اندام را تایید کرده است. با این حال، تعداد کمی از مطالعات روی موضوع قطعه‌بندی نمونه‌های سلولی متمرکز شده‌اند، که کاملاً متفاوت از قطعه‌بندی معنایی^۶ است. ^[۴] شبکه عصبی که تقسیم‌بندی نمونه را انجام می‌دهد، نه تنها باید بتواند دسته‌بندی شی را انجام دهد، بلکه باید نمونه شی را برای هر پیکسل متعلق به آن شناسایی کند.

۱-۳ اهداف تحقیق

در این پایان‌نامه، یک چارچوب یادگیری مبتنی بر روش خودنظارتی برای بهره‌برداری عمیق از ظرفیت شبکه‌های عصبی کانولوشن برای قطعه‌بندی هسته‌ها ارائه و پیاده‌سازی شده است. این وظیفه‌ی نماینده‌ی

^۳ Pipeline

^۴ Proxy task

^۵ Fine-tune

^۶ Semantic segmentation

پیشنهادی خودنظارتی شامل دو کار فرعی است، شامل یادگیری سه‌گانه مقیاسی^۷ و رتبه‌بندی شمارش^۸ است، که شبکه عصبی را به صورت خودکار برای یادگیری مستقل دانش قبلی در مورد اندازه و کمیت هسته با استفاده عمیق از اطلاعات غنی موجود در داده‌های خام وا می‌دارد.

۴-۱ ساختار پایان‌نامه

این پایان‌نامه شامل ۶ فصل است. فصل دوم دربرگیرنده‌ی پیش‌زمینه‌های مرتبط با پایان‌نامه است. در فصل سوم کارهای پیشین انجام شده در این زمینه بیان می‌گردد. در فصل چهارم مدل پیشنهادی ما برای مسئله‌ی نقل به بیان دیگر ارائه می‌گردد. فصل پنجم شامل آزمایش‌هایی است که برای مقایسه‌ی مدل ما و مدل‌های پیشین ارائه شده طراحی شده است، این فصل همچنین پیشنهادهایی برای کارهای آتی ارائه می‌دهد. فصل ششم نیز به نتیجه‌گیری می‌پردازد.

فصل ۲

مفاهیم اولیه


۱-۲ یادگیری خودنظارتی

یادگیری خودنظارتی ابزاری برای آموزش کامپیوتر برای انجام وظایف بدون ارائه اطلاعات داده شده با برچسب توسط انسان است. این زیرمجموعه‌ای از یادگیری بدون نظارت است که در آن نتایج یا اهداف توسط ماشین‌هایی بدست می‌آیند که اطلاعات را به صورت جداگانه برچسب گذاری، طبقه‌بندی و تجزیه و تحلیل می‌کنند و سپس بر اساس ارتباطات و همبستگی‌ها نتیجه گیری می‌کنند.

یادگیری خودنظارتی به سیستم های هوش مصنوعی این امکان را می‌دهد تا با وجود کمبود مجموعه داده‌های دارای برچسب، کارهای پیچیده را به ساده تبدیل کنند تا به یک خروجی دلخواه برسند. ایده اصلی آن تولید خودکار نوعی سیگنال نظارتی برای حل وظایف است بنابراین، به منظور پیش بینی خروجی، مدل باید برخی از الگوهای خوب را از داده‌ها استخراج کند، و نمایش خوبی بر روی فرآیند ایجاد کند.

تولید یک مجموعه داده با برچسب، خصوصا در تصاویر پزشکی که فراوانی زیادی دارند و حتما توسط متخصصان باید برچسب زده (یا حاشیه‌نویسی) شوند، بسیار گران است اما داده های بدون برچسب در حال تولید هستند. برای استفاده از این داده‌های فراوان از اطلاعات بدون برچسب، یک راه این است که اهداف یادگیری را به درستی تنظیم کنید تا از خود داده‌ها نظارت دریافت کنید.

یکی از وظایف یادگیری خودنظارتی، استخراج چندین تکه از یک تصویر و پیش بینی روابط بین تکه‌ها توسط مدل است.



شکل ۲-۱: مدل UNET استفاده شده

۲-۲ شبکه عصبی UNET

یک شبکه عصبی عمیق است که در سال ۲۰۱۵ برای قطعه‌بندی تصاویر پزشکی طراحی شد. ایده اصلی در شبکه عصبی کانولوشنال یادگیری نگاشت ویژگی^۱ های یک تصویر و بهره‌برداری از آن برای ایجاد نگاشت ویژگی‌های ظریف تر است. این در مشکلات طبقه بندی به خوبی کار می کند زیرا تصویر به بردار تبدیل می شود که برای طبقه بندی بیشتر استفاده می شود. اما در قطعه‌بندی تصویر، ما نه تنها باید نگاشت ویژگی را به بردار تبدیل کنیم بلکه باید تصویری را از این بردار بازسازی کنیم. کل ایده UNET حول این مشکل چرخیده است.

UNet از همان نقشه‌های مشخصه‌ای که برای انقباض استفاده می‌شود، برای تبدیل بردار به تصویر قطعه‌بندی شده استفاده می‌کند. این معماری به شکل U است و از سه بخش تشکیل شده است: انقباض، گلوگاه و قسمت انبساط. تعداد بلوک های انبساط مساوی تعداد بلوک انقباض است [۵].

شبکه‌ی عصبی استفاده شده در این روش، یک شبکه‌ی UNET است که مقاله‌ی [۶] از آن در راستای حل اشکال به هم ریخته به صورت پازل استفاده کرده است. این مدل که در شکل ۲-۱ به صورت شماتیک نمایش داده شده است، یک خودرمزگذار^۲ است که از بخش پایین رونده‌ی آن به عنوان رمزگذار و از قسمت بالا رونده‌ی آن به عنوان رمزگشا استفاده شده است.

فصل ۳

کارهای پیشین

در ادبیات بخش زیادی از کارهای انجام شده در راستای تصاویر پزشکی مربوط به مکان‌یابی و یافتن هسته سلول‌ها می‌باشد. در این فصل کار نفرات برگزیده‌ی مسابقه‌ی Kaggle BOWL 2018 را بررسی خواهیم کرد.

• تیم اول

این تیم از یک دسته مدل و همچنین افزایش داده و مرحله پس پردازشی استفاده کرده است. آنها از ۸ شبکه تماماً کانوولوشنال استفاده کرده اند و این بخش از مدل را ۴ بار تکرار کرده اند که در نهایت ۳۲ شبکه را آموزش می دهند. پایه اصلی هر ۸ شبکه، رمزگذار-رمزگشا می باشد. که ۶ تا از آنها از شبکه UNET استفاده شده و دو شبکه دیگر را شبکه های FPN تشکیل می دهند. در شبکه های رمزگذار از شبکه های ResNet استفاده شده است. این تیم برای جلوگیری از فرآیند پوشش بیش از حد دو استراتژی را در پیش گرفته است. اول استفاده از یک شبکه از پیش آموزش دیده روی دیتاست ImageNet و دوم استفاده از تولید و افزایش داده از ۲۴ روش مختلف مشخص استفاده شده است.

• تیم دوم

این تیم از یک شبکه مبتنی بر FPN استفاده کرده است که دو لایه‌ی آخر آن شخصی سازی شده است. که مکان ماسک بدست آمده را به صورت نسبی با مکان سلول از ۴ جهت (عمودی، افقی، ۴۵ درجه و ۱۳۵ درجه) بدست می آورد. ماسک بدست آمده در نهایت در یک فرآیند پس پردازشی

قرار گرفته و به محدوده سلول تبدیل می‌شود. این شبکه FPN نیز روی دیتاست ImageNet از پیش آموزش دیده می‌باشد. همچنین تابع هزینه‌ی جدیدی معرفی شد که نرخ خطای سایشی را کاهش می‌دهد. که در واقع ارزش اشیای کوچک را با اشیای بزرگ یکسان در نظر می‌گیرد. همچنین این تیم نیز از افزایش داده در هنگام آموزش و تست مدل استفاده کرده است.

- تیم سوم

این تیم از مدل Mask-RCNN که با دیتاست COCO از پیش آموزش دیده است استفاده کرده است. همچنین استفاده از افزایش داده با توجه به مقیاس عکس‌ها (کوچک کردن و بزرگ کردن) انجام شده است. آینه‌ای کردن و چرخاندن عکس از دیگر موارد افزایش داده این تیم بوده است. همچنین از افزایش داده در زمان تست نیز استفاده شده است [۷].

فصل ۴


روش پیشنهادی

این فصل به وظیفه‌ی نماینده‌ی پیشنهادی خودنظارتی و جزئیات آن می‌پردازد.

۴-۱ مجموعه داده سه‌گانه


در روش‌های یادگیری چندگانه، که هدف آن یادگیری یک فضای تعبیه شده^۱ است که شباهت بین نقاط داده را به دست می‌آورد، برای تشویق شبکه‌های عصبی به یادگیری ضمنی ویژگی‌های نمونه‌های هسته (مانند اندازه و تعداد هسته‌ها) به کار می‌رود. در روش یادگیری سه‌گانه ما یک تکه‌ی تصادفی با ابعاد مشخص از تصویر را برداشته، به عنوان نمونه‌ی لنگر^۲، سپس با کمی انتقال^۳، به میزان تصادفی و بین ۰ تا ۵۰ پیکسل، آن تکه تصویر مثبت^۴ را ایجاد می‌کنیم. انتظار می‌رود از نظر مقیاس و تعداد سلول‌ها عکس مثبت با تصویر اصلی مشابه باشد. برای یادگیری بهتر اطلاعات اندازه هسته‌ها در روش خودنظارتی، یک نمونه منفی^۵ حاوی هسته با اندازه‌های بزرگتر تولید می‌شود - یک تکه کوچکتر که به طور تصادفی از نمونه مثبت بریده می‌شود و اندازه آن را به اندازه‌ی تصویر مثبت تغییر می‌دهیم تبدیل می‌شود. انتظار می‌رود که تصویر منفی از نظر مقیاس بزرگتر از تصویر لنگر و تصویر مثبت باشد و از نظر تعداد سلول‌ها کوچکتر از تصویر مثبت باشد. از آنجایی که با دو مجموعه داده کار کردیم، برای

^۱ Embedding space
^۲ anchor
^۳ shift
^۴ positive
^۵ negative



شکل ۴-۱: نمونه‌های لنگر (برش قرمز)، مثبت (برش آبی) و منفی (برش سبز) در مجموعه داده‌ی MoNuSeg

مجموعه داده‌ی MoNuSeg که اندازه‌ی تصاویر آن 1000×1000 پیکسل است، طبق مقاله [؟]، اندازه‌ی لنگر و نمونه مثبت را 768×768 در نظر گرفته، و برش نمونه‌ی منفی از تصویر مثبت را برای ایجاد تنوع بیشتر، در اندازه‌های 512×512 ، 256×256 ، 128×128 و 64×64 انجام می‌دهیم و تصویر بریده شده را به اندازه‌ی 768×768 بزرگنمایی می‌کنیم تا نمونه‌ی منفی ایجاد شود. برای مجموعه داده‌ی Kaggle چون اندازه‌ی تصاویر 512×512 است، اندازه‌ی نمونه لنگر و مثبت را 384×384 در نظر گرفته و برش‌های تصویر منفی را در اندازه‌های 256×256 ، 128×128 و 64×64 انجام می‌دهیم. نمونه‌های لنگر، مثبت و منفی یک داده استاندارد سه‌گانه را تشکیل می‌دهند، که برای وظیفه‌ی نماینده در یادگیری خودنظارتی استفاده می‌شود.



شکل ۴-۲: مدل رمزگذار با وزن‌های مشترک

۲-۴ رویکرد خودنظارتی و وظیفه‌های نماینده

همانطور که گفته شد، برای پیش‌آموزش شبکه‌ی عصبی از دو وظیفه‌ی نماینده‌ی یادگیری سه‌گانه و شمارش رتبه‌بندی استفاده می‌کنیم. برای پیاده‌سازی این هدف، از ۳ رمزگذار^۶ با وزن‌های مشترک استفاده می‌کنیم که دو وظیفه ساختگی به منظور آموزش ویژگی‌های عکس‌ها طراحی شده است. وظیفه اول، سه‌گانه مقیاسی، مربوط به تشخیص اندازه و وظیفه دوم، رتبه‌بندی شمارش، مربوط به تعداد سلول‌های موجود در عکس می‌باشد.

توابع هزینه در این بخش به صورت زیر تعریف شده است:

۴-۲-۱ یادگیری سه‌گانه مقیاسی

در این بخش ابتدا خروجی مدل را به صورت خطی در آورده (z_a, z_p, z_n) و تابع هزینه برای تاثیر مقیاس که به صورت زیر تعریف می‌شود، روی آن‌ها اجرا کرده می‌شود [۱].

^۶encoder

$$L_{ST}(z_a, z_p, z_n) = \sum (max(\bullet, d(z_a, z_p) - d(z_a, z_n) + m^1))$$

در این فرمول m^1 حاشیه^۷ است (که به صورت تجربی ۱ در نظر گرفته می‌شود) و تابع d ، Pair-wiseDistance تعیین می‌شود. این تابع فاصله دوتایی دسته ای بین دو ورودی تابع را با استفاده از p-norm محاسبه می‌کند. با استفاده از این روش تلف سه گانه بدست می‌آید که شبکه فاصله ادراکی بین لنگر و نمونه‌های مثبت را در فضای ویژگی کاهش می‌دهد و عدم تشابه معنایی (مثل اندازه هسته) را بین لنگر و نمونه‌های منفی بزرگ می‌کند.

۲-۲-۴ شمارش رتبه‌بندی

این تابع هزینه فقط روی نمونه‌های مثبت و منفی برای تاثیر تعداد سلول ها در تصاویر اعمال می‌شود و مانند فرمول قبلی m^2 حاشیه است (که به صورت تجربی ۱ در نظر گرفته می‌شود). تابع f توسط یک لایه کاملاً کانولوشن پیاده سازی می‌شود.

$$L_{CR}(z_p, z_n) = \sum (max(\bullet, f(z_n) - f(z_p) + m^2))$$

در نهایت با استفاده از حاصل دو تابع فوق، اتلاف مدل خودنظارتی را به صورت زیر محاسبه می‌کنیم:

$$L = L_{ST} + L_{CR}$$

۳-۴ تنظیم روی وظیفه‌ی اصلی

وظیفه‌ی اصلی در اینجا دسته بندی هر پیکسل از عکس به سه دسته پیش‌زمینه، بدنه سلول و مرز سلول‌ها می‌باشد. پس در نهایت با استفاده از رمزگذار آموزش داده شده و اتصال آن به یک رمزگشا^۸ که وزن‌های آن به صورت تصادفی انتخاب شده است به این مهم دست می‌یابیم. در مقاله‌ی مرجع در بدنه‌ی رمزگذار، از شبکه‌ی ResNet101 استفاده شده است. ابتدا این شبکه را تست کردیم اما بدلیل پیچیدگی و حجم

^۷margin
^۸decoder

بالای آن از شبکه‌ی ارائه شده در مقاله [۶] جایگزین شد. این مدل ارائه شده یک UNET است که معماری آن به شکل U است. از قسمت رو به پایین آن به عنوان رمزگذار استفاده می‌کنیم و وظایف فوق را روی آن قسمت اجرا می‌کنیم و آن را پیش‌آموزش می‌کنیم تا ویژگی‌های نمونه‌ها را استخراج کند و وزن‌های شبکه را بروزرسانی کند. حال این وزن‌های بروزرسانی شده را به شبکه‌ی UNET کامل می‌دهیم و بخش رمزگشای آن را بصورت رندم وزن دهی می‌کنیم. حال این شبکه را به جهت قطعه‌بندی سلول‌ها با داده‌های حاشیه‌نویسی شده و با تابع اتلاف تعبیه شده‌ی Binary Cross Entropy^۹ آموزش می‌دهیم.

BCEWithLogitsLoss^۹

فصل ۵

آزمایش‌ها و نتایج

۵-۱ مجموعه داده

۵-۱-۱ مجموعه داده MoNuSeg 2018

مجموعه داده این چالش با حاشیه نویسی تصاویر بافتی چندین بیمار با تومور اندامهای مختلف (شامل کبد، کلیه، سینه، پروستات، مثانه، روده بزرگ و معده) و در ۱۸ بیمارستان تشخیص داده شد. این مجموعه داده حاوی تصاویر متنوع با رنگ آمیزی H&E و بزرگنمایی ۴۰ برابر است. رنگ آمیزی H&E یک پروتکل معمول برای افزایش تضاد یک قسمت بافتی است و معمولاً برای ارزیابی تومور (درجه بندی، مرحله بندی و غیره) استفاده می شود.

این مجموعه داده دارای یک مجموعه آموزشی، شامل ۳۰ تصویر حاشیه نویسی شده دستی، و یک مجموعه آزمایشی، شامل ۱۴ تصویر است. وضوح تصاویر هیستوپاتولوژیک 1000×1000 پیکسل است. حاشیه نویسی های هر تصویر در یک فایل XML که شامل قطعه بندی دقیق آن تصویر است قرار گرفته است [۴].

۵-۱-۲ مجموعه داده Kaggle Data science Bowl 2018

این تصاویر مجموعه متنوعی از تصاویر بیولوژیکی را تشکیل می‌دهند که در مجموع حاوی ده‌ها هزار هسته است. تنوع موجود در مجموعه داده‌ها نشان دهنده نوع تصاویر جمع آوری شده توسط محققان زیست‌شناس در دانشگاه‌ها، فناوری‌های زیستی و بیمارستان‌ها است. هسته‌های موجود در تصاویر از طیف وسیعی از موجودات زنده از جمله انسان، موش و مگس گرفته شده است. علاوه بر این، هسته‌ها در شرایط مختلفی از جمله لکه‌های فلورسنت و بافت شناسی، چندین بزرگنمایی و کیفیت متفاوت نورپردازی تحت تصویربرداری قرار گرفته‌اند. سرانجام، هسته‌ها در زمینه‌ها و حالت‌های مختلفی از جمله تک لایه‌های کشت یافته، بافت‌ها و جنین‌ها و تقسیم سلولی، استرس ژنوتوکسیک ظاهر می‌شوند. این مجموعه داده به منظور به چالش کشیدن توانایی الگوریتم برای تعمیم در میان این تغییرات طراحی شده است.

این مجموعه داده دارای دو بخش است (Stage1, Stage2) که ما از Stage1 استفاده کردیم. در راستای یکنواخت سازی، آنها را تکه^۱ کرده و به تصاویر ۵۱۲×۵۱۲ پیکسل تبدیل کردیم. مجموعه آموزشی Stage1 شامل ۱۱۶۲ تصویر حاشیه‌نویسی شده و مجموعه آزمایشی آن شامل ۱۲۶ تصویر حاشیه‌نویسی شده است. حاشیه‌نویسی‌ها به صورت مجموعه‌ای از ماسک‌ها برای هر تصویر هسته است. هر ماسک یک فایل PNG است که شامل قطعه‌بندی دقیق آن تصویر است قرار گرفته است [۸].

۵-۲ جمع‌بندی آزمایش

تا اینجا برای آموزش شبکه، در مرحله‌ی اول، دادگان آموزش Stage1 که را به صورت مجموعه‌ای سه‌گانه از لنگر، مثبت و منفی تبدیل کرده، و به عنوان مجموعه آموزشی به بخش رمزگذار شبکه می‌دهیم (در این بخش فقط از تصاویر اصلی استفاده کرده و نیازی به تصاویر حاشیه‌نویسی شده نیست). پس از اتمام آموزش این بخش، وزن‌های شبکه را به مرحله‌ی بعد انتقال می‌دهیم. در این مرحله از شبکه‌ی UNET کامل استفاده کرده و برای آموزش آن، از ۱۰٪ دادگان حاشیه‌نویسی شده‌ی آموزش Stage1 استفاده می‌کنیم. در نهایت شبکه UNET آموزش دیده را با دادگان آزمایش Stage1 تست می‌کنیم.

Patch^۱

۳-۵ ارزیابی و عملکرد

برای ارزیابی دقت کار مدل، مانند معیار ارزیابی به کار رفته در مسابقه‌ی Kaggle BOWL 2018 از Mean Average Precision استفاده می‌کنیم تا بتوانیم نتایج خود را با شرکت کنندگان این مسابقه مقایسه کنیم. این استراتژی بر اساس استراتژی شناسایی خطاهای سطح شیء است. شرکت کنندگان ماسک‌های هدف را شناسایی کرده که با تطابق این ماسک‌ها با ماسک‌های هدف و محاسبه TP^2 و FP^3 رتبه بندی شده بودند. تطبیق این دو ماسک تحت عنوان IOU محاسبه می‌شود که از رابطه زیر بدست می‌آید.

$$IOU = \frac{|A \cap B|}{|A \cup B|}$$

که A و B دو شیء مربوط به دو حالت هدف و محاسبه شده می‌باشد و عملگر || نشان دهنده ناحیه می‌باشد. حال برای محاسبه امتیاز شرکت‌کنندگان یک حالت حد در نظر گرفته شده و کمتر از این حد به عنوان خطا در نظر گرفته می‌شود. توسط IOU، صحت، دقت و امتیاز $F1$ محاسبه می‌شود. که روابط آن مطابق حالت زیر خواهد بود.

$$P(t) = \frac{TP(t)}{TP(t) + FP(t)}$$

$$R(t) = \frac{TP(t)}{TP(t) + FN(t)} \quad 4$$

$$F1(t) = \frac{2TP(t)}{2TP(t) + FP(t) + FN(t)}$$

اگر تیمی دقیقاً ماسک هدف را تشخیص دهد IOU برابر با ۱ می‌شود که بهترین حالت را شامل می‌شود. اما در عمل این امر امکان پذیر نیست و پوشش بخشی از ماسک هدف را می‌توان محاسبه نمود. به همین دلیل برای مقایسه به ازای مقادیر افزایشی IOU، امتیازی به صورت زیر محاسبه می‌شود.

$$S = \frac{1}{|T|} \sum_{t \in T} \frac{TP(t)}{TP(t) + FP(t) + FN(t)}$$


Where T = 0.10, 0.15,..., 0.95

بر اساس این معیار مدل خود را با تعداد دوره‌های^۵ مختلف سنجیدیم آموزش داده و ارزیابی کردیم. همچنین برای سنجش روش خود، دقیقاً همین شبکه‌ی UNET را این دور بدون پیاده‌سازی روش

^۲ True Positive
^۳ False Positive
^۴ False Negative
^۵ epoch

Epoch 500				Epoch 300				
test	validation		train	test	validation		train	
mAP	mAP	Loss	Loss	mAP	mAP	Loss	Loss	
0.2608	0.4923	0.1223	0.0771	0.2608	0.4669	0.13	0.0956	UNET-From-Scratch
0.2545	0.4803	0.1235	0.0807	0.2655	0.445	0.1266	0.0929	Self-Supervised-Model-(10Epoch)
0.2735	0.5047	0.1301	0.0789	0.2697	0.44	0.1245	0.0914	Self-Supervised-Model-(30Epoch)

جدول ۵-۱: نتایج ارزیابی




شکل ۵-۱: نمودار اتلاف بخش خودنظارتی مدل


خودنظارتی با همان ۱۰٪ داده‌ی آموزشی آموزش داده و با داده‌های آزمایشی تست کردیم، و آن مدل هم با معیار مذکور ارزیابی کردیم. نتایج این ارزیابی‌ها در جدول ۵-۱ ثبت شده است.

در نهایت این مدل در تعداد دور ۳۰ برای بخش خودنظارتی و ۵۰۰ برای بخش آموزش کلی شبکه، به بهترین نتیجه‌ی خود، یعنی $mAP=0.5047$ برای داده‌ی اعتبارسنجی^۶ و $mAP=0.2735$ برای داده‌ی آزمایشی رسید.

^۶ validation



شکل ۵-۲: نتایج حاصل از ۳۰ دور آموزش رمزگذار و ۳۰۰ دور آموزش UNET، $mAP=0.44$



شکل ۵-۳: نتایج حاصل از ۱۰ دور آموزش رمزگذار و ۵۰۰ دور آموزش UNET، $mAP=0.48$

۴-۵ پیشنهادات برای بهبود مدل در آینده

با بررسی نتایج و نمودارهای مدل طراحی شده، پی می‌بریم که مدل در بخش خودنظارتی دچار سازگاری بیش از حد^۷ می‌شود و دلیل اختلاف کم با مدل غیر خودنظارتی نیز همین است؛ برای بهبود عملکرد این مدل قصد داریم در آینده توابع تلف خود را تغییر داده (مثلاً به جای max از softmax استفاده کنیم) و شبکه‌ی رمزگذار را با آنها آموزش دهیم. همچنین برای جلوگیری از سازگاری بیش از حد شدن شبکه‌ی خودنظارتی روی داده‌ها از حملات خصمانه^۸ استفاده کنیم.

^۷ overfit
^۸ adversarial attacks

فصل ۶

نتیجه‌گیری

در این پایان‌نامه، یک چارچوب برای قطعه‌بندی سلولی با روش خودنظارتی ارائه و پیاده‌سازی شد. روش پیشنهادی شامل دو وظیفه فرعی یادگیری سه‌گانه مقیاسی و رتبه‌بندی شمارش است که شبکه عصبی را قادر می‌سازد به طور ضمنی دانش اندازه و کمیت هسته را بدست آورد. این مدل یادگیری خودنظارتی بر روی مجموعه داده Kaggle که دسترس عموم است ارزیابی شد و به دقت $mAP=0.5047$ دست یافت.

مراجع

- [1] F. Schroff, D. Kalenichenko, and J. Philbin. Facenet: A unified embedding for face recognition and clustering. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 815–823, 2015.
- [2] H. Chang, J. Han, A. Borowsky, L. Loss, J. Gray, P. Spellman, and B. Parvin. Invariant delineation of nuclear architecture in glioblastoma multiforme for clinical and molecular association. *IEEE Transactions on Medical Imaging*, 32(4):670–682, 2013.
- [3] X. Zhuang, Y. Li, Y. Hu, K. Ma, Y. Yang, and Y. Zheng. Self-supervised feature learning for 3d medical images by playing a rubik’s cube. *International Conference on Medical Image Computing and Computer Assisted Intervention*, pages 410–428, 2019.
- [4] X. Xie, J. Chen, Y. Li, L. Shen, K. Ma, and Y. Zheng. Instance-aware self-supervised learning for nuclei segmentation. *arXiv preprint arXiv:2007.11186*, 2020.
- [5] O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*, pages 234–241. Springer, 2015.
- [6] M. Salehi, A. Eftekhari, N. Sadjadi, M. H. Rohban, and H. R. Rabiee. Puzzle-ae: Novelty detection in images through solving puzzles. *arXiv preprint arXiv:2008.12959*, 2020.
- [7] J. C. Caicedo, A. Goodman, K. W. Karhohs, B. A. Cimini, J. Ackerman, M. Haghighi, C. Heng, T. Becker, M. Doan, C. McQuin, M. H. Rohban, S. Singh, and A. Carpenter. Nucleus segmentation across imaging experiments: the 2018 data science bowl. *Nature Methods*, 16:1247 – 1253, 2019.
- [8] Kaggle 2018 data science bowl. <https://bbbc.broadinstitute.org/BBBC038>.

واژه‌نامه

الف

آستانه Threshold
انتقال shift
الگو pattern
تلف، اتلاف loss
انقباض contraction
انبساط expansion
اعتبارسنجی validation

ت

تعبیه شده embedded
تنظیم fine-tune
تکه patch

چ

چارچوب framework
چگالی density

ح

حاشیه‌نویسی annotation
حاشیه margin
حمله خصمانه adversarial attack

خ

خود رمزگذار autoencoder
خط لوله pipeline
خودنظارتی self-supervised

د

دور epoch

ر

رمزگذار encoder
رمزگشا decoder
ریخت‌شناسی morphology

scale-wise مقیاسی	س
true positive مثبت واقعی	سازگاری بیش از حد
false positive مثبت کاذب	overfit
false negative منفی کاذب	ق
	segmentation قطعه‌بندی
ن	گ
feature map نگاشت ویژگی	bottleneck گلوگاه
و	ل
proxy task وظیفه نماینده	anchor لنگر
ه	م
nuclei هسته‌ها	dataset مجموعه داده
ی	set مجموعه
triplet learning یادگیری سه‌گانه	positive مثبت
	negative منفی

Abstract

Due to the widespread progress in the process of imaging tissue cells, the identification and diagnosis of complex diseases using machine learning methods has become very important. Recognizing cell characteristics such as size and shape are important factors in determining cell type, which can be achieved through learning methods such as deep neural network training. In this project, we intend to segment cells in microscopic images with a self-supervised learning method. The purpose of segmenting these images is to identify the nucleus in different cell types. The image data used to identify the core of the 2018 Kaggle Data Science Bowl is now available to the public.

Keywords: Self-supervised learning, Cell segmentation, Nucleus detection, Neural network



Sharif University of Technology

Department of Computer Engineering

B.Sc. Thesis

Self-supervised Cell Segmentation in Microscopic Images

By:

Bahar Jahani

Supervisor:

Dr. Mohammad Hossein Rohban

October 2020